MADSET - ENGINEERING

# ADVISE EVAL LAB

Sentetik reklam önerileri için karşılaştırmalı, tekrar üretilebilir değerlendirme sistemi

## 1 / Yönetici özeti

Teknik teslimat hazırdır. Laboratuvar 30 geliştirme, 10 ilk test ve sonradan dondurulan 12 yeni kör test vakası içerir. Gerçek müşteri verisi, reklam platformu API çağrısı ve otomatik bütçe değişikliği yoktur.

Üç yerel kural üreticisi ölçülmüştür. İlk 40 vakalık sette V3 yüzde 100 görünse de bu set geliştirme sürecinde tüketilmiştir. V3 tamamlandıktan sonra yeni 12-vaka seti SHA-256 ile dondurulmuş ve üretici değiştirilmeden final doğrulaması yapılmıştır.

### 2 / Yeni kör doğrulama

| Sürüm | İlk kör sonuç | Grader 1.1 | Karar doğruluğu |
|---|---|---|---|
| V1 | 0/36 (%0) | 0/36 (%0) | %8,3 |
| V2 | 0/36 (%0) | 0/36 (%0) | %41,7 |
| V3 | 24/36 (%66,7) | 27/36 (%75) | %83,3 |

Yorum: V3, V1'e göre yeni kör sette +75 yüzde puan ilerlemiştir. İlk kör koşu bir grader yanlış alarmını ortaya çıkardı; üretici tekrar çağrılmadan aynı transcript yeniden puanlandı.

Nihai sınır: İnsan uzman kalibrasyonu olmadan gerçek Madset ürünü için yayın onayı verilemez.

# DEĞERLENDİRME MİMARİSİ

## 3 / Rubric ve geçiş kapısı

Rubric veri-matematik, teşhis, kanıt-belirsizlik, stratejik uygunluk, ticari risk, uygulanabilirlik ve sadelik boyutlarını 0-4 aralığında puanlar. Kritik hata yüksek puanla telafi edilemez.

| Boyut | Ağırlık | Geçiş kanıtı |
|---|---|---|
| Veri ve matematik | 20 | Doğrulanmış iddia ve doğru payda |
| Teşhis doğruluğu | 20 | Doğru karar ve senaryoya özgü kavram |
| Kanıt ve belirsizlik | 15 | Grounded evidence ve dürüst sınır |
| Stratejik uygunluk | 15 | Karar-protokolü ve hedef uyumu |
| Ticari risk | 15 | Kapasite, marj ve aşağı yönlü risk |
| Uygulanabilirlik | 10 | Somut sonraki adım |
| Sadelik | 5 | KOBİ sahibinin anlayacağı dil |

Geçiş: en az 80/100, kabul edilen karar, sıfır F01-F08/FMT, en az yüzde 75 kavram kapsaması, karar sınıfına uygun protokol ve grounded evidence.

### 4 / Harness ve kayıt

Her trial sentetik girdi transcriptini, çıktıyı, gerekçeyi, puanı, semantik kapsama kanıtını, kritik hata kodlarını, süreyi ve sürüm metaverisini saklar. Harici adapter model, prompt, token ve - fiyatlar sabitlenirse - maliyet bilgisini taşır.

Karşılaştırma bütün trial'ları senaryo bazında kullanır. Grader değişiklikleri üreticiyi yeniden çağırmadan regrade ile aynı transcript üzerinde uygulanır; eski sonuç korunur.

# KÖR SET BULGULARI

## 5 / Gerçek hata türleri

| Vaka | Beklenen | Bulgu |
|---|---|---|
| ADV-041 | WAIT | Gecikmeli randevu geri dönüşü öneride yeterince kapsanmadı. |
| ADV-044 | MAINTAIN | Hedef altı satış CPA yerine gereksiz DIAGNOSE seçildi. |
| ADV-049 | DIAGNOSE | İptal bilgisi ölçüm arızası gibi yorumlandı. |

Kör sonuç görüldükten sonra V3 değiştirilmedi. Bu vakalar V4 geliştirmesine alınırsa sonraki kabul için yeni bir holdout oluşturulmalıdır.

## 6 / Grader güvenilirliği

Negatif mutasyon: 8/8 hedef hata yakalandı. Pozitif kontrol: 19/19 doğru kabul edildi; gözlenen yanlış alarm yüzde 0.

Kör sette "garanti veya uygunsuz iddia kullanmayın" cümlesi ilk grader tarafından F03 sayıldı. Negasyon bağlamı düzeltildi, regresyon testi eklendi ve mevcut transcript grader 1.1 ile yeniden puanlandı.

Bu küçük, el yapımı kontrol kümesi tam Türkçe anlam doğruluğu değildir. Hazır kör CSV iki uzmanın bağımsız overall_pass ve yedi boyut puanı vermesine olanak sağlar. Analiz aracı agreement, Cohen kappa ve grader-vs-consensus recall/yanlış-alarm oranını hesaplar.

Claude dev koşusu: Sonnet 4.6, 30 V3 önerisinin 25'ini geçirdi (%83,33); karar 30/30, ortalama puan 91,04 ve kritik hata sıfırdır. Beş başarısız vaka ADV-001, 003, 014, 017 ve 038'dir; ortak eksik uygulanabilir eşik/zaman ve mevcut huni-ekonomi verisinin tam kullanılmamasıdır.

Koşu 57.952 girdi + 20.395 çıktı tokenı kullandı; ortalama yargıç gecikmesi 13,89 saniyedir. Fiyatlar sabitlenmediği için maliyet null'dır, sıfır değildir. ADV-001 tek kontrolde 92,5, toplu koşuda 76,25 aldığı için LLM yargıç değişkenliği görünürdür.
Henüz yok: doldurulmuş iki uzman etiketi ve insan etiketlerine karşı kalibre edilmiş LLM judge. Bu nedenle stratejik uzmanlık onaylanmış sayılmaz.

# TESLİMAT VE YAYIN KAPISI

## 7 / Tamamlananlar

| Teslim | Durum |
|---|---|
| 52 sentetik vaka; dev + iki holdout dalgası | Tamamlandı |
| Şema, hash doğrulama ve gold izolasyonu | Çalışır |
| Üç sürüm, 39 anahtarsız test, temiz-klon koruması | Geçti |
| Semantik kapsama + 30-vaka Claude yargısı | Çalışır; insan kalibrasyonu bekliyor |
| Trial-bazlı karşılaştırma ve regrade | Çalışır |
| JSON, CSV, HTML, Markdown ve PDF rapor | Tamamlandı |
| İki uzman için kör değerlendirme paketi | Hazır; insan etiketi yok |

### 8 / Kapanması gereken dış kapılar

İnsan: Reklam/performans uzmanı ile ürün/KOBİ uzmanı kör paketi doldurmalı; uyuşmazlıklar üçüncü değerlendirme ile kapatılmalıdır.

Ürün: Gerçek Madset öneri motoru sentetik-input adapterine bağlanmalı; model, prompt, token ve maliyet kaydıyla yeni bir kör sette ölçülmelidir.

Üretim: Sentetik eval geçişi satış veya kârlılık artışını kanıtlamaz. Üretim izleme, kullanıcı geri bildirimi ve uygun A/B ölçümü ayrıca gerekir.

### 9 / Nihai karar

Advise Eval Lab teknik teslimata hazırdır. V3, yeni kör sette yüzde 75 geçişle ilk sürümden açıkça iyidir ve üç gerçek hatayı görünür bırakmıştır. İnsan uzman kalibrasyonu tamamlanmadan gerçek ürün için "yayına hazır" denmemelidir.

Kaynak dayanağı: Advise Lab gereksinimleri ve kullanıcı tarafından sağlanan AI ajan eval rehberi. Yerel karar sınıfları, ağırlıklar, semantik kavram kuralları ve baseline üreticiler bu laboratuvarın tasarım kararlarıdır.