MADSET - ENGINEERING

ADVISE EVAL LAB

Sentetik reklam önerileri için karşılaştırmalı, tekrar üretilebilir değerlendirme sistemi

1 / Yönetici özeti

Teknik teslimat hazırdır. Laboratuvar 30 geliştirme, 10 ilk test ve sonradan dondurulan 12 yeni kör test vakası içerir. Gerçek müşteri verisi, reklam platformu API çağrısı ve otomatik bütçe değişikliği yoktur.

Üç yerel kural üreticisi ölçülmüştür. İlk 40 vakalık sette V3 yüzde 100 görünse de bu set geliştirme sürecinde tüketilmiştir. V3 tamamlandıktan sonra yeni 12-vaka seti SHA-256 ile dondurulmuş ve üretici değiştirilmeden final doğrulaması yapılmıştır.

2 / Yeni kör doğrulama

Sürüm	İlk kör sonuç	Grader 1.1	Karar doğruluğu
V1	0/36 (%0)	0/36 (%0)	%8,3
V2	0/36 (%0)	0/36 (%0)	%41,7
V3	24/36 (%66,7)	27/36 (%75)	%83,3

Yorum: V3, V1'e göre yeni kör sette +75 yüzde puan ilerlemiştir. İlk kör koşu bir grader yanlış alarmını ortaya çıkardı; üretici tekrar çağrılmadan aynı transcript yeniden puanlandı.

Nihai sınır: İnsan uzman kalibrasyonu olmadan gerçek Madset ürünü için yayın onayı verilemez.

DEĞERLENDİRME MİMARİSİ

3 / Rubric ve geçiş kapısı

Rubric veri-matematik, teşhis, kanıt-belirsizlik, stratejik uygunluk, ticari risk, uygulanabilirlik ve sadelik boyutlarını 0-4 aralığında puanlar. Kritik hata yüksek puanla telafi edilemez.

Boyut	Ağırlık	4 puan çıpası
Veri ve matematik	20	Tüm iddialar doğrulanır
Teşhis doğruluğu	20	Belirti, neden ve karşı olasılıklar uygun ayrılır
Kanıt ve belirsizlik	15	Kanıt yeterliliği dürüst ve yerinde
Stratejik uygunluk	15	Sektör, hedef ve kanala tam uygun
Ticari risk ve fayda	15	Harcama, kapasite, marj ve aşağı yönlü risk ele alınır
Uygulanabilirlik	10	Yapılabilir net sonraki adım
Sadelik ve iletişim	5	Kısa, doğal ve jargonsuz

Geçiş: en az 80/100, kabul edilen karar, sıfır F01-F08/FMT, en az yüzde 75 kavram kapsaması, karar sınıfına uygun protokol ve grounded evidence. Aktif rubrik: 1.1-provisional-ui.4.

4 / Harness ve kayıt

Her trial sentetik girdi transcriptini, çıktıyı, gerekçeyi, puanı, semantik kapsama kanıtını, kritik hata kodlarını, süreyi ve sürüm metaverisini saklar. Harici adapter model, prompt, token ve - fiyatlar sabitlenirse - maliyet bilgisini taşır.

Karşılaştırma bütün trial'ları senaryo bazında kullanır. Grader değişiklikleri üreticiyi yeniden çağırmadan regrade ile aynı transcript üzerinde uygulanır; eski sonuç korunur.

KÖR SET BULGULARI

5 / Gerçek hata türleri

Vaka	Beklenen	Bulgu
ADV-041	WAIT	Gecikmeli randevu geri dönüşü öneride yeterince kapsanmadı.
ADV-044	MAINTAIN	Hedef altı satış CPA yerine gereksiz DIAGNOSE seçildi.
ADV-049	DIAGNOSE	İptal bilgisi ölçüm arızası gibi yorumlandı.

Kör sonuç görüldükten sonra V3 değiştirilmedi. Bu vakalar V4 geliştirmesine alınırsa sonraki kabul için yeni bir holdout oluşturulmalıdır.

6 / Grader güvenilirliği

Negatif mutasyon: 8/8 hedef hata yakalandı. Pozitif kontrol: 19/19 doğru kabul edildi; gözlenen yanlış alarm yüzde 0.

Kör sette "garanti veya uygunsuz iddia kullanmayın" cümlesi ilk grader tarafından F03 sayıldı. Negasyon bağlamı düzeltildi, regresyon testi eklendi ve mevcut transcript grader 1.1 ile yeniden puanlandı.

Bu küçük, el yapımı kontrol kümesi tam Türkçe anlam doğruluğu değildir. Hazır kör CSV iki uzmanın bağımsız overall_pass ve yedi boyut puanı vermesine olanak sağlar. Analiz aracı agreement, Cohen kappa ve grader-vs-consensus recall/yanlış-alarm oranını hesaplar.

Claude tekrar güvenilirliği: Aynı 30 öneri üç kez yargılandı. Geçişler %83,33 / %93,33 / %90; 27/30 oybirliği, ortalama ikili anlaşma %93,33 ve Fleiss kappa 0,6625. Değişken vakalar ADV-001, 003 ve 038; çoğunlukta kalanlar ADV-001, 014 ve 017'dir.

Toplam 90 yargı 173.856 girdi + 62.023 çıktı tokenı ve tahmini 1,451913 USD kullandı. Tekrar tutarlılığı ölçülmüştür; insan etiketlerine karşı semantik doğruluk kalibrasyonu hâlâ açıktır.
Henüz yok: doldurulmuş iki uzman etiketi ve insan etiketlerine karşı kalibre edilmiş LLM judge. Bu nedenle stratejik uzmanlık onaylanmış sayılmaz.

TESLİMAT VE YAYIN KAPISI

7 / Tamamlananlar

Teslim	Durum
52 sentetik vaka; dev + iki holdout dalgası	Tamamlandı
Şema, hash doğrulama ve gold izolasyonu	Çalışır
Üç sürüm, 51 test, 90-yargı güvenilirliği	Geçti
Semantik kapsama + 30-vaka Claude yargısı	Çalışır; insan kalibrasyonu bekliyor
Trial-bazlı karşılaştırma ve regrade	Çalışır
JSON, CSV, HTML, Markdown ve PDF rapor	Tamamlandı
İki uzman için kör değerlendirme paketi	Hazır; insan etiketi yok

8 / Kapanması gereken dış kapılar

İnsan: Reklam/performans uzmanı ile ürün/KOBİ uzmanı kör paketi doldurmalı; uyuşmazlıklar üçüncü değerlendirme ile kapatılmalıdır.

Ürün: Gerçek Madset öneri motoru sentetik-input adapterine bağlanmalı; model, prompt, token ve maliyet kaydıyla yeni bir kör sette ölçülmelidir.

Üretim: Sentetik eval geçişi satış veya kârlılık artışını kanıtlamaz. Üretim izleme, kullanıcı geri bildirimi ve uygun A/B ölçümü ayrıca gerekir.

9 / Nihai karar

Advise Eval Lab teknik teslimata hazırdır. V3, yeni kör sette yüzde 75 geçişle ilk sürümden açıkça iyidir ve üç gerçek hatayı görünür bırakmıştır. İnsan uzman kalibrasyonu tamamlanmadan gerçek ürün için "yayına hazır" denmemelidir.

Kaynak dayanağı: Advise Lab gereksinimleri ve kullanıcı tarafından sağlanan AI ajan eval rehberi. Yerel karar sınıfları, ağırlıklar, semantik kavram kuralları ve baseline üreticiler bu laboratuvarın tasarım kararlarıdır.